

YOCO Fast decode 优化报告

日期：2026-09-06。开发分支 dev/yoco-fast-decode-20260906，基于已发布的 d7dcdd9e837531530c7aa4b03af534ca6d4704fa，即已经包含上一轮 Prefill 优化的 Fast。

结果

同一物理 B200，A/B/B/A、每版每个负载 6 次：128-token 输入、64-token 输出时，B64/B128/B256 的 TPOT 降低 **7.1%-10.1%**，端到端吞吐提高 **6.0%-8.5%**。小 batch、长输入及 Prefill 的独立结果见下表，不把局部加速推广到全部负载。

同卡公开 trace 输出吞吐 **1031.65 → 1037.25 tok/s**，变化 **+0.54%**；TTFT / ITL / E2E P95 分别变化 **+0.08% / +6.43% / -3.66%**。负的延迟变化表示改善。固定到达率限制了总吞吐，这不是最大容量测试。

Fast 仍不保证 bitwise。固定前缀抽样覆盖 128 个预测位置，每位置完整词表 154,880；本次 Top-1 均一致，数值差异见后表。它不替代模型任务质量或长期稳定性评估。

实现与选择过程

- 稳定 C128 的 12 步 profile 中，960 次专家 GEMM 累计 140.455 ms，约每步 11.7 ms，是主要优化方向。
- 最终候选同样 12 步、960 次 GEMM 的累计时间为 114.411 ms，降低 18.54%。这是实际生成中的累计 kernel 时间；路由可能变化，不将它单独当作纯 kernel 因果证据。
- 分别筛选 W13/W2 配置，保留相同 M tile 以复用专家分派；验证包含均匀和集中路由。
- Triton 私有小 M 表只命中精确尺寸。最初按邻近 bucket 外推在 M48/65 集中路由上回退，因此没有采用。
- M64/128/256 使用预先测量的 CUTLASS tactic，要求完整 CUDA Graph、uniform batch 且每请求一个 token。多 token prefill、混合图、未测尺寸和 eager 调用继续使用原 backend 策略。
- 仅加载六条 GEMM1/GEMM2 tactic；FlashInfer 官方加载器检查 GPU/CUDA/library 元数据。已验证环境为 FlashInfer 0.6.8.post1、CUDA 13.1、cuBLAS 13.2.1、cuDNN 91900、B200。
- 保留已有 BF16 权重、128 experts、Top-8、SwiGLU clamp、[up, gate] 布局与共享 workspace；没有增加权重副本。
- FlashInfer 的 bucket 上限覆盖完整 scheduler budget，避免大 prefill 被映射到最后一个 decode bucket。16 项强 clamp 检查通过，1024-token prefill 的两个 GEMM 确认使用未缓存的 heuristic tactic。
- 不在线 autotune。依赖不匹配或已有其他显式 autotune cache 时回退；Align 不使用本轮配置。

启用需满足原 standalone Fast 的 B200/L3/BF16/TP1/KV-sharing 条件，图捕获上限不超过 256。关闭新增 CUTLASS decode 选择：


```
--additional-config '{"yoco_fast_decode_cutlass": false}'
```

这保留 Triton 调参与已有 Prefill 策略。

固定负载测量

相同模型、GPU 5、BF16、maxlen16384、budget8192、maxseq256、memory .72 ; prefix cache 关闭， chunked prefill 与 KV-sharing fast-prefill 开启，FULL_AND_PIECEWISE 图捕获到 256。请求先全部入队再统一恢复调度。每个负载先预热，记录全部样本；没有挑选最快样本。吞吐比例由相同 token 工作量的端到端时间计算，包含 Prefill 与调度。长输入的 TPOT 也可能包含混合调度干扰。

负载		基线 ms	候选 ms	吞吐变化	两对吞吐变化
decode-b1-s128		414.75	411.20	+0.86%	+0.65% / +0.97%
decode-b8-s128		690.03	679.12	+1.61%	+1.37% / +1.92%
decode-b32-s128		992.15	974.20	+1.84%	+1.85% / +1.82%
decode-b64-s128		1127.93	1049.36	+7.49%	+7.36% / +8.07%
decode-b128-s128		1529.78	1410.16	+8.48%	+8.43% / +8.48%
decode-b256-s128		2130.34	2009.98	+5.99%	+6.23% / +5.58%
decode-b1-s2048		485.45	481.97	+0.72%	+0.90% / +0.38%
decode-b32-s2048		2055.03	2037.04	+0.88%	+0.90% / +0.86%
decode-b128-s2048		5819.82	5691.36	+2.26%	+2.35% / +2.17%
prefill-b1-s1024		84.79	84.80	-0.01%	-0.19% / -0.37%
prefill-b8-s1024		151.84	153.25	-0.92%	-1.56% / +0.44%
prefill-b1-s4096		82.78	82.42	+0.44%	-1.86% / -0.09%
prefill-b8-s4096		535.10	532.25	+0.53%	+0.97% / +0.28%
输入长度	Batch	基线 TPOT ms		候选 TPOT ms	TPOT 降低
128	1	6.086		6.041	0.75%
128	8	9.468		9.284	1.94%
128	32	13.348		13.041	2.31%
128	64	14.822		13.538	8.66%
128	128	18.791		16.897	10.08%
128	256	25.302		23.509	7.09%
2048	1	6.482		6.429	0.83%
2048	32	20.203		19.829	1.85%
2048	128	49.662		48.035	3.27%



数值检查

75 项相关回归通过，包含 Align；40 项独立 FP32 reference 检查通过，Triton 调参前后在这些输入上逐字节相同。缓存 CUTLASS 的 16 项强 clamp 检查覆盖 limit=.5/10、均匀/集中路由以及 M64/128/256/1024。

完整模型比较通过替换采样输出 token ID 固定后续前缀，原始 logits 在替换之前抓取；不改变模型算术。每个 batch 重复两次，目标位于首、中、尾；两端实际 batch 记录一致。该探针不用于计时。KL 用本地 CPU FP64 log-softmax 计算，定义为 KL(基线 || 候选)。

Batch	抽样位置	Logits bitwise	平均 KL	最大 KL	Top-1 一致率
1	8	True	0	0	100.0%
8	24	True	0	0	100.0%
32	24	True	0	0	100.0%
64	24	False	6.95366e-05	0.000816989	100.0%
128	24	False	7.69044e-05	0.000649444	100.0%
256	24	False	9.44549e-05	0.00106687	100.0%

CUTLASS 在部分大 batch 的重复结果也不是逐位确定的，原始重复差异保存在 fixed-prefix-comparison.json。本次内部筛选阈值为平均 KL <.01、最大 KL <.1，最终通过；这只是数值筛选，不是任务准确率门槛。首轮实现曾误命中小 prefill，B1 出现较大 KL 波动，因此被拒绝并收窄为单 token 图；该版本的速度不作为本报告最终结果。

AIPerf 公开 trace


Mooncake FAST'25 toolagent_trace 源时间 300-900 秒，600 秒固定到达、1×、3643 请求，context <=81920。源文件 23608 行，context 过滤保留 23492 行；冻结窗口 SHA256：

680e526d49545258c0ca5b635d0004a44cce2ce990d533ac32024cefee1f0170。公开 trace 只有时间、长度及 prefix hash；是合成负载回放，不是在线 agent 任务或模型质量数据。


两端各自先 smoke50，再长测至完全排空。相同物理 GPU、服务参数、客户端参数、默认 BOS 行为， 每轮独立 cache salt；AIPerf 0.12.0，record-processors=1，并发上限 512。服务 maxlen81920、budget32768、maxseq256、memory .85，开启 prefix cache。共享节点、一次完整前后对照、没有声明延迟 SLO，因此结果为 diagnostic。

指标	基线 Fast	候选 Fast
成功 / 计划	3643/3643	3643/3643
输出 tok/s	1031.646	1037.250
输入 tok/s	48941.972	49207.794
完成请求/s	5.842	5.873
回放至排空 s	623.623	620.255
600 秒后排空尾部 s	23.623	20.255
调度 lag P99 ms	12.366	11.212
最大客户端并发	216.000	213.000
最大 running	210.000	206.000
最大 waiting	21.000	21.000
Prompt token cache hit %	37.453	37.297
最大 metrics 间隔 s	0.998	0.708
错误数	0	0
输出长度不匹配	0.0	0.0
回放调度降速	0.0	0.0
Preemptions	0.0	0.0
客户端审计	True	True
服务端审计	True	True
Token accounting	True	True
最终 running	0.0	0.0
最终 waiting	0.0	0.0
指标	基线 P50 / P95 / P99	候选 P50 / P95 / P99
TTFT s	1.589 / 2.843 / 3.297	1.578 / 2.845 / 3.345
ITL ms	86.044 / 272.476 / 475.738	81.887 / 289.995 / 478.111
E2E s	4.692 / 62.492 / 91.350	4.524 / 60.203 / 86.938

YOCO L3 Fast / BF16 / standalone TP1 / same B200 GPU 5
Mooncake FAST25 toolagent t300-900s / 1x / context <=81,920 / unique cache salts
Completed 3643/3643 and 3643/3643; shared-node diagnostic



Same-GPU Fast trace: queue buildup and complete drain



两端实际输入/输出 token 数逐请求一致：True。客户端配置只允许 cache salt、输出目录不同；服务命令一致。完整配置比较见 `trace-config-equivalence.json`。

保留的中间问题与证据

- 初次 profile 断言错误包含排空尾部；独立审计确认采样的 12 步均为 C128，原日志和退出码保留。
- 隔离 runtime 缺少 `workspace_init` fixture，补入仓库原 fixture 后完成检查；最终 75 项一起重跑通过。
- 远端 CPU 汇总两次 SIGSEGV，未改变 GPU 结果。原始张量复制本地后正常计算；不宣称已查明 CPU 崩溃根因。
- 小 prefill 数值筛选失败的候选保留为 V2；V3 及最终版本加入阶段和 uniform/single-token 边界。

- 失败与未采用的候选不混入最终配对时间，最终目录为 before-b、candidate-final-a、candidate-final-b、before-final。

主要结果：short-comparison.json/csv、fixed-prefix-comparison.json、trace-comparison.json/csv。逐项源码哈希、原始日志、脚本、profile、张量和 AIPerf 原始导出保存在实验工作区 yoco_results/fast-decode-optimization-b200-20260906/；GPU runtime 位于 /data/yoco-fast-decode-20260906/。仓库 docs 发布报告、图表与汇总数据。

临时服务已停止，GPU 5 恢复 0 MiB 使用；原 Pod UID/restartCount 和 8600/8610/8620 服务保持。两轮检查区间内未观察到 GPU 错误，uncorrectable ECC 计数均为 0。完整收尾证据见实验工作区的 FINAL_VALIDATION.json、gpu-final.txt、pod-final.txt 与 protected-final.txt。